

Avance 5: Modelo Final

Ensamblas y Selección de Modelo Óptimo

Reconocimiento de Acciones Humanas (HAR) para VisionOps

Landy Haydee Schlebach Osorio
Carlos Pano Hernández
Carlos Fernando Del Castillo Rey

Tec de Monterrey, Campus Estado de México – Equipo MNA-V

Asesor académico: Dr. Gerardo Camacho

Patrocinador industrial: Alignity IQ Edge, LLC

Junio 2026

Abstract

Se desarrollaron y evaluaron 7 modelos de ensamble para reconocimiento de acciones humanas (HAR) en el dataset InHARD. Se incluyeron 2 modelos base (V-JEPA 2, DINOv2) y 5 ensambles (3 homogéneos por votación, 2 heterogéneos por stacking/blending). El modelo ganador es V-JEPA 2 con accuracy 78.54%, Macro F1 0.7063 y AUC-ROC promedio 0.9573. Se generan 5 gráficos de análisis detallado: matriz de confusión, métricas por clase, curvas ROC, distribución de confianza y balance de clases.

1 Introducción y Contexto

VisionOps es un sistema de IA para digitalización de manufactura. El pipeline de HAR utiliza embeddings pre-calculados de V-JEPA 2 y DINOv2 (1024 dimensiones, congelados) en el dataset InHARD con 3,425 clips de 12 acciones industriales.

2 Metodología

2.1 Modelos Evaluados (7 total)

Table 1: Comparativa de 7 Modelos en Datos de Validación (685 muestras)

Modelo	Accuracy	Macro F1	Tipo	Mejora
V-JEPA 2	0.7854	0.7063	Base	0.00%
DINOv2	0.7635	0.7220	Base	-2.79%
Stacking	0.7580	0.6037	Heterogéneo	-3.49%
Blending	0.7484	0.5606	Heterogéneo	-4.70%
Soft Voting	0.5153	0.4443	Homogéneo	-34.42%
Hard Voting	0.4876	0.3697	Homogéneo	-37.90%
Weighted Voting	0.4029	0.3452	Homogéneo	-48.73%

2.2 Estrategias de Ensamble

Homogéneos: Soft Voting (promedio probabilidades), Hard Voting (modo predicción), Weighted Voting (ponderado por F1 histórico).

Heterogéneos: Stacking (meta-features con LogisticRegression), Blending (hold-out set 50/50).

3 Resultados y Gráficos

3.1 Gráfico 1: Matriz de Confusión




Figure 1: Matriz 12×12 del modelo V-JEPA 2. Diagonal fuerte indica alta precisión (78.54%). Algunas confusiones entre clases similares (ej: picking left vs picking front).

3.2 Gráfico 2: Métricas por Clase




Figure 2: Precision, Recall, F1-score por acción. Mayoría de clases F1 ≥ 0.65 . Clases con pocos ejemplos tienen rendimiento más variable.

3.3 Gráfico 3: Curvas ROC (One-vs-Rest)




Figure 3: 12 curvas ROC (una por clase). Mean AUC = 0.9573 (Excelente discriminación). Todas las curvas cercanas a esquina superior izquierda.

3.4 Gráfico 4: Distribución de Confianza




Figure 4: Confianza promedio 0.85. Buena separación entre predicciones correctas (confianza mayor) e incorrectas. Modelo bien calibrado.

3.5 Gráfico 5: Balance de Clases vs Accuracy




Figure 5: Correlación inversa: clases con pocos ejemplos tienen menor accuracy. Oportunidad: aumentar datos de clases minoritarias.

4 Análisis y Hallazgos

- **Modelos Base:** V-JEPA 2 superior (78.54%). DINOv2 competitivo pero menor accuracy.
- **Ensambls Heterogéneos:** No mejoran sobre base. Stacking 75.80%, Blending 74.84%.
- **Ensambls Homogéneos:** Degradación severa (51-40%). Los embeddings pre-entrenados congelados no se benefician de promediación.
- **Discriminación:** AUC 0.9573 indica excelente separación de clases.
- **Calibración:** Confianza 0.85 correlaciona bien con acierto.

5 Modelo Final Seleccionado

V-JEPA 2 es el ganador entre 7 modelos evaluados.

Especificación:

- Backbone: Vision Joint Embedding Predictive Architecture v2
- Embeddings: 1024 dims (congelados)
- Clasificador: Regresión Logística (12 clases)
- Latencia: ¡5ms (tiempo real)

Performance:

- Accuracy: 78.54%
- Macro F1: 0.7063
- AUC-ROC: 0.9573 (Excelente)
- Confianza promedio: 0.85

Justificación: Máxima accuracy, excelente discriminación (AUC 0.9573), eficiencia temporal, buena calibración, escalable a nuevas acciones.

6 Recomendaciones

1. **Despliegue inmediato:** Integrar V-JEPA 2 en vision-ops-backend con threshold confianza 0.75
2. **Validación HITL:** Registrar predicciones en SQLite, validación en producción
3. **Mejora continua:** Recolectar datos reales, fine-tuning selectivo, aumentar clases minoritarias (SMOTE)
4. **Benchmarking:** Comparar contra operadores humanos

7 Conclusión

Se completó exitosamente el análisis de 7 modelos (2 base + 5 ensambles). V-JEPA 2 es el ganador con 78.54% accuracy y AUC 0.9573. El modelo base pre-entrenado es más efectivo que las estrategias de ensamble evaluadas. Está listo para despliegue en producción.