

Estrategias de Visión Artificial de Nueva Generación para la Excelencia Operacional: Un Marco Integral de VisionOps y Modelos de Mundo en la Manufactura Inteligente

La convergencia de la visión por computador de gran escala y los sistemas industriales ha dado lugar a un cambio de paradigma en el que el monitoreo pasivo se transforma en una capacidad de razonamiento proactivo. El presente reporte detalla la arquitectura técnica y operativa del sistema conceptual “AI Co-Pilot para el piso de producción”, un ecosistema de VisionOps diseñado para integrar la comprensión profunda de la dinámica temporal con la precisión espacial en entornos de fabricación. Este análisis se fundamenta en la adopción de modelos fundacionales de vanguardia, como V-JEPA y DINOv3, y su aplicación sobre conjuntos de datos industriales de referencia como InHARD, abordando tanto la implementación en tiempo real como el análisis retrospectivo para la optimización de procesos.

1. El Conjunto de Datos InHARD: Aportaciones y Desafíos de Generalización

El Industrial Human Action Recognition Dataset (InHARD) representa un hito en el desarrollo de técnicas de aprendizaje para la interacción humano-robot en contextos industriales. Este dataset aporta una estructura multimodal robusta que combina secuencias de vídeo RGB con datos de esqueletos 3D (RGB+S), permitiendo un análisis detallado de la biomecánica del operario en el cumplimiento de tareas de montaje.¹ Con una magnitud que supera los 2 millones de fotogramas capturados a partir de 16 sujetos distintos, InHARD clasifica 13 acciones industriales fundamentales, incluyendo movimientos como "recoger", "colocar", "atornillar" y "sostener".¹ La inclusión de datos de esqueleto en formato BVH, que registra la ubicación 3D de 17 articulaciones principales y sus respectivas rotaciones, facilita el entrenamiento de modelos que no dependen exclusivamente de la apariencia visual, mitigando problemas de iluminación o cambios de vestimenta.¹

Un elemento distintivo de InHARD es la categorización de los operarios en "expertos" y "principiantes" mediante un umbral de ejecución de 6 minutos para la tarea completa, lo que permite al sistema co-piloto aprender a identificar no solo la acción, sino la eficiencia y los posibles errores de fatiga.¹ No obstante, su generalización a una planta real en Estados Unidos, como las situadas en Texas, enfrenta limitaciones críticas. La captura se realizó en un entorno de laboratorio controlado con tres cámaras C920 fijas (cenital y laterales a $\pm 45^\circ$), una

disposición que rara vez coincide con la infraestructura de cámaras de seguridad industriales o los sistemas de inspección en línea, donde los ángulos de visión son subóptimos y abundan las oclusiones por maquinaria pesada.¹ Además, existe un riesgo documentado de "filtración de identidad del sujeto", donde el modelo puede memorizar las proporciones físicas de los 16 voluntarios europeos en lugar de aprender patrones de movimiento universales, lo que degradaría la precisión ante la diversidad demográfica de una planta en Texas.⁵

2. Sinergia de Modelos Fundacionales: Integración de DINOv3 y V-JEPA 2.1

El diseño de un pipeline de VisionOps eficiente exige la combinación de dos tipos de representaciones visuales: la comprensión estática de alta resolución y la comprensión dinámica de la causalidad física. El uso de DINOv3 como backbone de imagen y V-JEPA 2.1 como codificador de vídeo permite una orquestación que minimiza la redundancia computacional mientras maximiza la profundidad del hallazgo visual.

2.1. DINOv3: Percepción Espacial y Segmentación de Precisión

DINOv3 actúa como el componente fundamental para la detección de objetos y la delimitación de la zona de trabajo. Al ser un modelo fundacional entrenado mediante aprendizaje auto-supervisado (SSL) a una escala de 7 mil millones de parámetros, DINOv3 genera características densas de alta calidad que permiten segmentar herramientas, piezas y operarios sin necesidad de un etiquetado manual exhaustivo.⁶ En el piso de producción, su utilidad radica en la fase de extracción de frames clave para tareas que requieren precisión de píxel, como la verificación de la presencia de componentes pequeños o la detección de defectos superficiales.⁶ Mediante el uso de técnicas de "Gram Anchoring", DINOv3 mantiene la integridad de sus representaciones incluso en secuencias de larga duración, evitando la degradación que sufren otros modelos SSL.⁶

2.2. V-JEPA 2.1: Modelado del Mundo y Dinámica Temporal

Mientras DINOv3 se centra en el "qué" y el "dónde", V-JEPA 2.1 se especializa en el "cómo" y el "por qué". La arquitectura Joint-Embedding Predictive Architecture (JEPA) de Meta rompe con el enfoque tradicional de reconstrucción de píxeles, optando por predecir representaciones latentes de segmentos de vídeo enmascarados.⁹ V-JEPA 2.1 introduce una "pérdida predictiva densa" que supervisa todos los tokens del vídeo, tanto los visibles como los ocultos, forzando al modelo a comprender las relaciones espaciales y temporales profundas.¹¹ Para el co-piloto de producción, V-JEPA 2.1 es el motor que permite la anticipación de acciones humanas y la detección de anomalías en la secuencia de montaje. Su capacidad para procesar clips cortos mediante un tokenizer 3D de tipo "tubelet" (con tamaño 2 en la dimensión temporal) le permite capturar la fluidez del movimiento del trabajador, algo que los modelos basados en imágenes individuales omiten por completo.⁹

2.3. Estructuración del Pipeline sin Redundancias

La arquitectura propuesta evita el procesamiento duplicado mediante una separación clara de responsabilidades. El pipeline opera bajo el siguiente esquema:

- 1. **Fase de Identificación de Escena:** Se extraen frames a baja frecuencia (v.gr., 1 FPS) procesados por DINOv3 para actualizar el inventario de objetos y las fronteras de seguridad de la zona de trabajo.⁷
- 2. **Fase de Seguimiento de Acción:** Se procesan clips de vídeo (v.gr., 16-64 frames) mediante el encoder de V-JEPA 2.1 para reconocer la actividad actual del operario y predecir el siguiente paso del proceso.¹³
- 3. **Fase de Fusión Sensorial:** Las representaciones espaciales de DINO se inyectan en el Predictor de V-JEPA mediante mecanismos de atención cruzada, proporcionando al modelo de mundo el contexto exacto de qué objetos está manipulando el operario, lo que aumenta la robustez del reconocimiento ante oclusiones.³

Modelo	Función Principal	Entrada Recomendada	Ventaja en la Fábrica
DINOv3	Segmentación y Detección	Frames individuales (Alta Res)	Zero-shot; no requiere etiquetas para nuevos objetos. ⁷
V-JEPA 2.1	Reconocimiento de Acciones	Clips de vídeo (Temporal)	Entiende la física y predice movimientos futuros. ⁹
Fusión	Razonamiento Contextual	Características latentes	Reduce errores por sombras o reflejos en piezas metálicas. ³

3. Estado del Arte y Referencias Bibliográficas (2024-2026)

La investigación actual se ha desplazado hacia modelos que no solo clasifican datos, sino que comprenden la estructura física del entorno industrial. A continuación, se detallan las referencias clave que sustentan este proyecto.

- **Causal-JEPA: Learning World Models through Object-Level Latent Interventions**

(arXiv, 2026): Propone un modelo de mundo que utiliza intervenciones a nivel de objeto para inducir un sesgo inductivo causal, permitiendo al co-piloto entender por qué una acción falló.¹⁶

- **V-JEPA 2.1: Unlocking Dense Features in Video Self-Supervised Learning (Meta FAIR, 2026):** El manual técnico definitivo para la implementación de representaciones temporales consistentes y planificación 10 veces más rápida en tareas robóticas.⁹
- **DINOv3: Major milestone toward universal vision backbones (Meta AI, 2025):** Describe las estrategias de escalado a 1.7 mil millones de imágenes y el uso de post-hoc strategies para alinear la visión con el lenguaje natural.⁶
- **Industrial Foundation Model (IFMsys): A System Architecture (IEEE, 2025):** Presenta un marco para la aplicación de modelos fundacionales en el ciclo de vida del producto, destacando la necesidad de salidas confiables y alineación con mecanismos industriales.¹⁷
- **Grounding Foundational Vision Models with 3D Human Poses (arXiv, 2025):** Estudio que valida la superioridad de fusionar V-JEPA con datos de pose explícitos en el benchmark InHARD, especialmente en escenas con alta oclusión.³
- **A Low-Cost Real-Time Framework for Industrial Action Recognition (arXiv, 2024):** Introduce LRIAR, un sistema que utiliza Grounding DINO para auto-etiquetado, facilitando el despliegue rápido en nuevas líneas de producción sin costes de manual labeling.¹⁸
- **Why AI systems don't learn and what to do about it (arXiv, 2026):** Análisis crítico de Yann LeCun sobre la necesidad de módulos de observación, acción y meta-control para lograr inteligencia autónoma.¹⁹
- **Wearable Foundation Models for Activity Understanding (arXiv, 2026):** Survey sobre modelos que analizan trayectorias a largo plazo, útil para el seguimiento de la fatiga del operario durante turnos completos.²⁰
- **Smart Cameras: The Future of Industrial Efficiency (Zebra/FAIR, 2025):** Informe sobre la integración de IA en el sensor para reducir la latencia en inspecciones críticas de alta velocidad.¹⁴
- **ISA-95 and America's Digital Manufacturing Transformation (Bowdark, 2025):** Analiza el ROI de implementar estándares de integración de datos en la industria estadounidense, fundamental para la capa de NLP y ERP.²²

4. Arquitecturas de Referencia para VisionOps

El sistema requiere tres arquitecturas diferenciadas para cubrir las necesidades operativas de la planta: la respuesta inmediata, el análisis estratégico y la persistencia de estado.

4.1. Arquitectura de Tiempo Casi Real (Latencia < 100ms)

Esta arquitectura está diseñada para la asistencia en vivo y la seguridad del operario. Se prioriza el procesamiento en el borde (Edge) para evitar los retardos de la red.²³

- **Ingesta:** Captura de streams RTSP desde cámaras inteligentes IP.

- **Procesamiento Edge:** Utiliza una versión destilada de V-JEPA 2.1 (ViT-B o ViT-L) optimizada para inferencia en GPU de bajo consumo o NPU dedicada.²⁴
- **Lógica:** Un comparador de estado rápido valida la acción detectada contra el SOP (Standard Operating Procedure) almacenado en caché local.
- **Interfaz:** Generación de alertas mediante superposición visual en monitores de línea o señales audibles mediante un motor de texto a voz ligero.

4.2. Arquitectura de Análisis Post-Turno (Batch Analytics)

Enfocada en la auditoría de calidad y la optimización de procesos a largo plazo, donde la precisión total es más importante que la velocidad.²⁶

- **Almacenamiento:** Las bitácoras visuales se consolidan en un servidor central al final del turno.
- **Procesamiento Centralizado:** Uso de modelos de gran escala (DINOv3 ViT-7B y V-JEPA 2.1 ViT-G) para procesar el 100% de los frames capturados.⁷
- **Indexación:** Los hallazgos se vectorizan y se almacenan en una base de datos vectorial para permitir búsquedas semánticas (v.gr., "encuentra todos los momentos donde el operario olvidó el sello de seguridad").²⁸
- **Salida:** Generación de informes de cumplimiento de procesos y métricas OEE enviadas al ERP.

4.3. Arquitectura de Gemelo Digital Ligero (Estado + Eventos)

Esta capa no busca una simulación física total, sino una representación digital del estado actual de la planta basada en eventos discretos.³⁰

- **Esquema de Datos:** Sigue el estándar ISA-95 para definir objetos de equipo y personal.³²
- **Motor de Eventos:** Cada detección de acción exitosa dispara un evento que actualiza el estado del "activo" en el gemelo digital (p.ej., Máquina_1: Estado = "Mantenimiento_Preventivo").³³
- **Visualización:** Un dashboard web que muestra la ubicación y actividad de todos los recursos en tiempo real, permitiendo a los gerentes de planta tomar decisiones informadas sobre la asignación de personal.³¹

5. Riesgos, Mitigaciones y Desafíos Operativos

La implementación en un entorno real como Texas exige una gestión rigurosa de los riesgos técnicos y legales.

5.1. Privacidad y Cumplimiento Normativo (Texas TDPESA)

A diferencia del GDPR europeo, la ley de Texas (TDPESA) pone un énfasis particular en el consentimiento explícito para la recopilación de "identificadores biométricos".³⁶

- **Mitigación:** El sistema debe configurarse para el procesamiento de "características latentes" que no permitan la reconstrucción del rostro. El uso de modelos de esqueleto (como los sugeridos por InHARD) permite monitorizar la acción sin almacenar datos que identifiquen biométricamente al individuo, reduciendo la superficie de riesgo legal.³

5.2. Sesgo de Dominio y Drift de Cámara

El rendimiento de un modelo entrenado en Europa puede degradarse por el ruido visual típico de las naves industriales de Texas (iluminación halógena, vibración constante, polvo en las lentes).³⁵

- **Mitigación:** Implementar un sistema de "monitoreo de drift" que detecte cambios sutiles en la nitidez o alineación de las cámaras, disparando alertas de mantenimiento preventivo.⁴⁰ Se recomienda el uso de aprendizaje por transferencia (Transfer Learning) con un pequeño set de datos capturado localmente para "alinear" los modelos fundacionales con la realidad de la planta específica.⁷

5.3. Eficiencia Económica de la Inferencia

El coste por millón de tokens (CPM) es el factor determinante en la viabilidad del VisionOps. Mientras que las GPUs de gama alta (H100) ofrecen el mayor throughput, su coste horario es elevado.²⁴

- **Mitigación:** Utilizar cuantización a FP8 para duplicar el rendimiento en GPUs compatibles y recurrir a modelos destilados para tareas de baja complejidad.²³ Para aplicaciones que no requieren baja latencia, el procesamiento por lotes (Batch) en instancias de tipo "spot" puede reducir los costes de infraestructura hasta en un 60%.²⁷

6. Capa NLP: Orquestación y Conectividad con el MES/ERP

La capa de procesamiento de lenguaje natural (NLP) transforma las detecciones de vídeo en información útil para la gestión empresarial, actuando como la interfaz entre la IA visual y los sistemas de ejecución de manufactura (MES).

6.1. RAG y Razonamiento sobre Bitácoras

El patrón Retrieval-Augmented Generation (RAG) permite al co-piloto responder preguntas complejas basándose en la historia visual de la planta. Al chunkear y vectorizar los registros de eventos generados por V-JEPA, el sistema puede "recuperar" los momentos exactos de una falla de proceso para que el LLM genere una explicación coherente.²⁸ Para evitar la "ceguera estructural" del RAG tradicional, el sistema debe utilizar metadatos de tiempo y ubicación para filtrar la búsqueda antes de realizar la similitud vectorial, garantizando que el contexto recuperado sea relevante para la máquina o el operario consultado.⁴⁵

6.2. Function Calling e Integración Estructurada

Para interactuar con el MES o el ERP, se utiliza el patrón de "Function Calling", donde el LLM identifica la necesidad de una acción administrativa a partir de un hallazgo visual. Por ejemplo, si el sistema de visión detecta un derrame, el co-piloto puede llamar automáticamente a la función `crear_ticket_mantenimiento(ubicacion="Zona_B", tipo="Limpieza_Quimica")`.²⁹ Es imperativo que toda comunicación siga el estándar ISA-95, emitiendo resúmenes en formato JSON que detallen los recursos, el personal y los materiales involucrados, facilitando la auditoría y el cumplimiento de normativas de calidad como la ISO 13485.³¹

Patrón de Diseño	Aplicación Concreta	Beneficio Operativo
Agentic RAG	Auditoría de incidentes pasados	Reduce el tiempo de investigación de fallos de horas a minutos. ⁴⁶
Metadata Filtering	Cumplimiento de roles de seguridad	Asegura que solo el personal autorizado acceda a datos sensibles. ²⁹
JSON ISA-95	Sincronización con el ERP	Automatiza el registro de producción y el consumo de materiales. ³²

7. Conclusiones y Recomendaciones Estratégicas

El despliegue de un "AI Co-Pilot para el piso de producción" basado en modelos fundacionales como V-JEPA 2.1 y DINOv3 representa un salto cualitativo hacia la manufactura autónoma. La capacidad de estos modelos para aprender representaciones universales permite superar las limitaciones de los datasets tradicionales como InHARD, adaptándose rápidamente a las condiciones específicas de las plantas industriales en Texas. Para maximizar el retorno de inversión, se recomienda una estrategia híbrida que combine el procesamiento en el borde para la seguridad en tiempo real con el procesamiento en la nube para el análisis estratégico, siempre bajo un marco de gobernanza de datos que respete la privacidad del trabajador y cumpla con los estándares internacionales de integración industrial.

Próximos Experimentos

Hipótesis	Métrica	Datos Necesarios	Esfuerzo
-----------	---------	------------------	----------

La fusión de características de esqueleto 3D con V-JEPA 2.1 mejora la detección de acciones en un 15% bajo oclusiones parciales.	Macro F1-Score	Clips de InHARD + Datos de CoMotion. ³	Medio
La técnica de Gram Anchoring en DINOv3 reduce el drift de segmentación en turnos de 12 horas comparado con DINOv2.	mIOU (mean Intersection Over Union)	Vídeo continuo de 12h de la línea de montaje. ⁶	Alto
La cuantización INT8 de V-JEPA 2.1 en NPU dedicada permite alcanzar 30 FPS con un consumo inferior a 10W.	Latencia (ms) y Consumo (W)	Modelo cuantizado y hardware Silex EP-200Q. ²⁵	Bajo
El uso de RAG con filtrado de metadatos temporales reduce las alucinaciones del co-piloto en un 40% al analizar incidentes de seguridad.	Hallucination Score / Precisión de Respuesta	Bitácora de eventos JSON + Consultas de auditoría. ⁴⁵	Medio

Works cited

1. Industrial Human Action Recognition Dataset InHARD - GitHub, accessed April 26, 2026, <https://github.com/vhavard/InHARD>
2. InHARD - Industrial Human Action Recognition Dataset in the Context of Industrial Collaborative Robotics - Zenodo, accessed April 26, 2026,

- <https://zenodo.org/records/4003541>
3. (PDF) Grounding Foundational Vision Models with 3D Human Poses for Robust Action Recognition - ResearchGate, accessed April 26, 2026, https://www.researchgate.net/publication/397479487_Grounding_Foundational_Vision_Models_with_3D_Human_Poses_for_Robust_Action_Recognition
 4. [2511.05622] Grounding Foundational Vision Models with 3D Human Poses for Robust Action Recognition - arXiv, accessed April 26, 2026, <https://arxiv.org/abs/2511.05622>
 5. Can Large Language Models Detect Methodological Flaws? Evidence from 'Gesture Recognition for UAV-Based Rescue Operation Based on Deep Learning' - arXiv, accessed April 26, 2026, <https://arxiv.org/html/2604.14161v1>
 6. DINOv3 | Research - AI at Meta, accessed April 26, 2026, <https://ai.meta.com/research/publications/dinov3/>
 7. DINOv3 - Meta AI, accessed April 26, 2026, <https://ai.meta.com/research/dinov3/>
 8. DINOv3 Guide: Train Meta's Self-Supervised Vision Model - Roboflow Blog, accessed April 26, 2026, <https://blog.roboflow.com/train-dinov3/>
 9. Why Meta's V-JEPA 2.1 model is a massive step forward for real-world AI - TechTalks, accessed April 26, 2026, <https://bdttechtalks.com/2026/03/23/v-jepa-2-1/>
 10. LeWorldModel and the Case for Stable Latent World Models | by Adnan Masood, PhD., accessed April 26, 2026, <https://medium.com/@adnanmasood/leworldmodel-and-the-case-for-stable-latent-world-models-0e4c33ca0f3c>
 11. V-JEPA 2.1: Unlocking Dense Features in Video Self-Supervised Learning - arXiv, accessed April 26, 2026, <https://arxiv.org/html/2603.14482v1>
 12. V-JEPA 2.1: Unlocking Dense Features in Video Self-Supervised Learning - Hugging Face, accessed April 26, 2026, <https://huggingface.co/papers/2603.14482>
 13. README.md - artykbayevk/vjepa21 - GitHub, accessed April 26, 2026, <https://github.com/artykbayevk/vjepa21/blob/main/README.md>
 14. Smart Cameras: The Future of Industrial Efficiency and Precision in Machine Vision | Zebra, accessed April 26, 2026, <https://www.zebra.com/us/en/blog/posts/2025/smart-cameras-the-future-of-industrial-efficiency-and-precision-in-machine-vision.html>
 15. CoboGesture: A Continuous Hand Gesture Dataset and Recognition Method for Human-Collaborative Robot Interaction - IEEE Xplore, accessed April 26, 2026, <https://ieeexplore.ieee.org/iel8/6287639/11323511/11394765.pdf>
 16. [2602.11389] Causal-JEPA: Learning World Models through Object-Level Latent Interventions - arXiv, accessed April 26, 2026, <https://arxiv.org/abs/2602.11389>
 17. (PDF) Industrial Foundation Model - ResearchGate, accessed April 26, 2026, https://www.researchgate.net/publication/389771469_Industrial_Foundation_Model
 18. A Low-Cost Real-Time Framework for Industrial Action Recognition Using Foundation Models - arXiv, accessed April 26, 2026, <https://arxiv.org/html/2403.08420v2>

19. The Scaling Wall and the Architectural Renaissance: A Path Toward Autonomous Learning | by Volkan Erol, PhD. | Mar, 2026, accessed April 26, 2026, <https://volkan-erol.medium.com/the-scaling-wall-and-the-architectural-renaissance-a-path-toward-autonomous-learning-9d5471c181af>
20. [2604.02711] Foundation Models Defining A New Era In Sensor-based Human Activity Recognition: A Survey And Outlook - arXiv, accessed April 26, 2026, <https://arxiv.org/abs/2604.02711>
21. Wearable Foundation Models Should Go Beyond Static Encoders - arXiv, accessed April 26, 2026, <https://arxiv.org/html/2603.19564>
22. ISA-95 & America's Digital Manufacturing Transformation - Bowdark Consulting, accessed April 26, 2026, <https://www.bowdark.com/blog/isa95-and-americas-digital-manufacturing-transformation>
23. GPU vs CPU for Computer Vision: AI Inference Optimization Guide - XenonStack, accessed April 26, 2026, <https://www.xenonstack.com/blog/gpu-cpu-computer-vision-ai-inference>
24. AI Inference Cost Economics in 2026: GPU FinOps Playbook | Spheron Blog, accessed April 26, 2026, <https://www.spheron.network/blog/ai-inference-cost-economics-2026/>
25. NPU vs. CPU: Edge AI Benchmarks for Real-Time Vision - Silex Technology, accessed April 26, 2026, <https://www.silextechnology.com/unwired/npu-vs-cpu-object-detection-benchmarks>
26. Real-Time vs Batch Processing A Comprehensive Comparison for 2025 - TiDB, accessed April 26, 2026, <https://www.pingcap.com/article/real-time-vs-batch-processing-comparison-2025/>
27. Batch vs. Real-Time Processing: Understanding the Differences - DZone, accessed April 26, 2026, <https://dzone.com/articles/batch-vs-real-time-processing-understanding-the-differences>
28. RAG for Enterprise Response: Architecture Guide - Redis, accessed April 26, 2026, <https://redis.io/blog/rag-for-enterprise-response/>
29. Enterprise RAG Architecture Patterns Explained (Beginner to Advanced) - Medium, accessed April 26, 2026, <https://medium.com/@vasanthancomrads/enterprise-rag-architecture-patterns-explained-beginner-to-advanced-92e4d4a08781>
30. Machine Vision Software Trends 2025: AI, 3D & No-Code - Mech-Mind, accessed April 26, 2026, <https://www.mech-mind.com/blog/machine-vision-software-trends.html>
31. Inline Quality Control and AI in Injection Molding - Vision Systems 2025 - TEDESolutions, accessed April 26, 2026, <https://www.tedesolutions.pl/en/blog/inline-ai-vision-systems-quality-control-injection-molding>
32. ISA-95 framework and layers - Siemens, accessed April 26, 2026,

- <https://www.siemens.com/en-us/technology/isa-95-framework-layers/>
33. ISA-95 Common Object Model - 4 Concept, accessed April 26, 2026, <https://reference.opcfoundation.org/ISA-95/v100/docs/4>
34. ISA-95 diagrams - Rhize documentation, accessed April 26, 2026, <https://docs.rhize.com/isa-95/isa-95-diagrams/>
35. Improve AI Spill or Leakage Detection on Production Floors - visionplatform.ai, accessed April 26, 2026, <https://visionplatform.ai/ai-spill-or-leakage-detection-on-production-floors/>
36. Privacy Laws & Business International Report 184 - Covington & Burling LLP, accessed April 26, 2026, <https://www.cov.com/-/media/files/corporate/publications/2023/08/texas-enacts-comprehensive-privacy-law-plb-international184.pdf>
37. 2026 Workplace Privacy Laws in U.S., Europe and Worldwide - Apploye, accessed April 26, 2026, <https://apploye.com/blog/workplace-privacy-laws/>
38. Key Compliance Laws for Remote Employee Monitoring & Data Protection - Worklytics, accessed April 26, 2026, <https://www.worklytics.co/blog/key-compliance-laws-for-remote-employee-monitoring-data-protection>
39. Vision Tips - Industrial Vision Systems, accessed April 26, 2026, <https://www.industrialvision.co.uk/tag/vision-tips>
40. Automate Conference Agenda for Automate Show, accessed April 26, 2026, <https://www.automateshow.com/agenda/conference>
41. Industrial Robotics Vision Systems: Sub-Millimeter Precision - AI CERTs, accessed April 26, 2026, <https://www.aicerts.ai/news/industrial-robotics-vision-systems-sub-millimeter-precision/>
42. The truth about AI inference costs: Why cost-per-token isn't what it seems - EDN, accessed April 26, 2026, <https://www.edn.com/the-truth-about-ai-inference-costs-why-cost-per-token-isnt-what-it-seems/>
43. Which AI Processing Approach Should I Choose: Real-Time vs Batch?, accessed April 26, 2026, <https://zenvanriel.com/ai-engineer-blog/which-ai-processing-approach-should-i-choose-realtime-vs-batch/>
44. RAG Architecture for Regulated Industries - DEV Community, accessed April 26, 2026, <https://dev.to/wolyra/rag-architecture-for-regulated-industries-c9m>
45. Building Enterprise-Grade RAG: Seven Architectural Innovations Beyond Vector Search, accessed April 26, 2026, <https://community.sap.com/t5/technology-blog-posts-by-sap/building-enterprise-grade-rag-seven-architectural-innovations-beyond-vector/ba-p/14348376>
46. Agentic RAG: Architecture Patterns That Actually Work for Enterprise AI - DEDICATTED, accessed April 26, 2026, <https://dedicatted.com/insights/agentic-rag-architecture-patterns-that-actually-work-for-enterprise-ai>