

Avance 6: Conclusiones Clave

Viabilidad de Implementación y Estrategia de Despliegue en Producción

VisionOps – Reconocimiento de Acciones Humanas en Manufactura

Landy Haydee Schleich Osorio
Carlos Pano Hernández
Carlos Fernando Del Castillo Rey

Tec de Monterrey, Campus Estado de México – Equipo MNA-V

Asesor académico: Dr. Gerardo Camacho

Patrocinador industrial: Alignity IQ Edge, LLC

Junio 2026

Abstract

Este avance final (Avance 6) evalúa la viabilidad de implementación del modelo V-JEPA 2 en producción. Se realiza análisis exhaustivo de criterios de éxito, rendimiento del modelo, recomendaciones clave y selección de plataforma cloud. Tras evaluación de AWS, Azure, GCP e IBM Watson, se recomienda AWS como plataforma prioritaria por su superioridad en escalabilidad, costo y servicios ML-específicos. Se proporciona arquitectura de producción, procedimientos de implementación y tareas accionables para stakeholders.

1 Ejecutivo

1.1 Verdict de Implementación

RECOMENDACIÓN: IMPLEMENTAR EN PRODUCCIÓN [APROBADO]

El modelo V-JEPA 2 cumple con todos los criterios de éxito establecidos:

- Accuracy 78.54% (exceeds 75% target)
- AUC-ROC 0.9573 (excellent discrimination)
- Latencia ¡5ms (meets real-time requirement)
- Confiabilidad de calibración: 0.85 (good)
- No requiere revisión de fases anteriores

Plataforma Recomendada: AWS (SageMaker + Lambda + RDS)

2 Evaluación de Viabilidad

2.1 Criterios de Éxito Establecidos

Table 1: Validación contra Criterios de Éxito Predefinidos

Criterio	Meta	Logrado	Status
Accuracy en validación	$\geq 75\%$	78.54%	OK
Macro F1-Score	≥ 0.70	0.7063	OK
AUC-ROC promedio	≥ 0.90	0.9573	OK
Latencia inferencia	< 10 ms	< 5 ms	OK
Confianza calibrada	> 0.80	0.85	OK
Cobertura de clases	12/12	12/12	OK
Estabilidad del modelo	$\pm 2\%$	$< 1\%$	OK

2.2 Análisis de Readiness

Fortalezas del Modelo:

- Discriminación excelente (AUC 0.9573)
- Confianza bien calibrada (0.85 media)
- Latencia compatible con tiempo real (¡5ms)
- Backbone pre-entrenado (V-JEPA 2) robusto
- Embeddings congelados = reproducibilidad garantizada
- Simple architecture (Logistic Regression) = fácil mantenimiento

Áreas de Mejora Identificadas:

- Clases minoritarias (n¡50) tienen accuracy variable (50-70%)
- Accuracy global 78.54% deja margen para 21.46% de mejora
- Confusiones entre clases similares (picking left/front)
- Dataset actual limitado a 3,425 ejemplos

3 Respuesta a Preguntas Clave

3.1 ¿Rendimiento suficiente para producción?

SÍ. El modelo alcanza 78.54% accuracy superando la meta de 75%. En contexto industrial:

- AUC 0.9573 indica excelente separabilidad de clases
- Confianza 0.85 permite filtro de predicciones inciertas
- Latencia ¡5ms permite monitoreo en tiempo real
- Matriz confusión muestra errores predecibles (no aleatorios)
- Recomendación: Usar threshold confianza 0.75 en producción

3.2 ¿Existe margen para mejorar?

SÍ, significativamente. Oportunidades identificadas:

1. **Aumentar datos:** De 3,425 a 10,000+ ejemplos (SMOTE para clases raras)
2. **Fine-tuning selectivo:** Descongelar últimas capas de V-JEPA 2 con datos reales
3. **Ensamblados adaptados:** Entrenar meta-learner con datos reales (no validación)
4. **Augmentación:** Rotaciones, zoom, oclusión en videos
5. **Nuevas arquitecturas:** Vision Transformers (ViT) como alternativa

Estimación: Mejora potencial hasta 85-88% con estrategias anteriores.

3.3 Recomendaciones Clave de Implementación

Table 2: Recomendaciones Prioritarias por Fase

Fase	Recomendación	Prioridad
Inmediata	Desplegar V-JEPA 2 en AWS SageMaker	CRÍTICA
	Configurar monitoring y alertas	CRÍTICA
	Implementar threshold confianza 0.75	ALTA
Corto plazo (1-3 meses)	Recolectar datos reales de planta	ALTA
	Validación HITL con operadores	ALTA
	Fine-tuning selectivo con datos reales	MEDIA
Mediano plazo (3-6 meses)	Aumentar dataset a 10,000+ ejemplos	MEDIA
	Explorar ensambles meta-learner adaptados	MEDIA
Largo plazo (6+ meses)	Evaluación de Vision Transformers	BAJA
	Análisis de interpretabilidad (SHAP/LIME)	BAJA

3.4 Tareas Accionables para Stakeholders

3.4.1 Rol: Data Engineering

- * Crear pipeline de ingesta de datos en tiempo real desde YOLO detector
- * Configurar almacenamiento en S3 con política de retención (90 días)
- * Validar calidad de embeddings (V-JEPA y DINOv2) en producción
- * Implementar logging de predicciones y confianza en RDS
- * Automatizar reentrenamiento semanal con datos nuevos

3.4.2 Rol: DevOps / Cloud Architecture

- * Configurar VPC en AWS con seguridad TLS/SSL
- * Desplegar modelo en SageMaker Endpoint (multi-AZ)
- * Crear Lambda function para inference (cold start ¡500ms)
- * Configurar autoscaling basado en throughput (100-500 req/s)
- * Implementar CloudWatch dashboards para monitoreo

3.4.3 Rol: ML Operations

- * Establecer baseline de drift detection (accuracy ¡75% = alert)
- * Definir SLOs: 99.9% uptime, ¡10ms latency p95
- * Crear procedimiento de rollback en 5 minutos
- * Validar modelo monthly contra nuevos datos
- * Documentar decisiones en MLflow

3.4.4 Rol: Production Floor / Manufacturing

- * Entrenar operadores en interpretación de alertas (confianza ¡ 0.75)
- * Definir acciones cuando modelo predice con baja confianza
- * Recolectar feedback de operadores (casos borderline)
- * Registrar mejoras observadas en OEE (Overall Equipment Effectiveness)
- * Participar en validación HITL (human-in-the-loop)

4 Evaluación de Plataformas Cloud

4.1 Comparativa AWS vs Azure vs GCP vs IBM Watson

Table 3: Comparativa Multidimensional de Plataformas Cloud

Aspecto	AWS	Azure	GCP	IBM Watson
Escalabilidad	5/5	4.5/5	4.5/5	3.5/5
Servicios ML	5/5	4/5	5/5	3/5
Facilidad de Uso	4/5	4.5/5	4/5	3.5/5
Costo	4/5	3.5/5	4.5/5	3/5
Integración Datos	5/5	4.5/5	4.5/5	3/5
Soporte Técnico	5/5	4.5/5	4/5	3.5/5
Comunidad	5/5	4.5/5	4.5/5	2.5/5
Experiencia del Equipo	4/5	3/5	3/5	2/5
SCORE TOTAL	37/40	32.5/40	33.5/40	24.5/40

4.2 Análisis Detallado por Proveedor

4.2.1 AWS (Amazon Web Services)

Fortalezas:

- SageMaker: platform ML nativa con features avanzadas (model registry, feature store)
- Lambda: serverless para inference con auto-scaling
- RDS: base datos relacional managed para predicciones
- S3: almacenamiento escalable con versioning
- CloudWatch: monitoring y logging integrado
- Experiencia del equipo: Alto (múltiples proyectos previos)
- Costo: Competitivo con descuentos por volumen
- Comunidad: Gigantesca, recursos abundantes

Debilidades:

- Curva de aprendizaje para servicios avanzados
- Precio inicial puede parecer alto
- Requiere gestión de IAM roles/policies

Arquitectura Propuesta (AWS):

```
[YOLO Detector] -> [Lambda] -> [SageMaker Endpoint] -> [RDS]
                    |
                    +-> [CloudWatch] -> [Alerts]
```

4.2.2 Azure (Microsoft Azure)

Fortalezas:

- Azure ML: plataforma integrada con VSCode
- Integración con ecosistema Microsoft (Teams, Office)
- CosmosDB: base datos NoSQL con replicación global
- Precio competitivo para empresas con licencias Microsoft

Debilidades:

- Servicios menos especializados que AWS/GCP
- Documentación fragmentada entre servicios
- Experiencia del equipo: Baja

4.2.3 Google Cloud Platform (GCP)

Fortalezas:

- Vertex AI: plataforma unificada para ML
- BigQuery: almacenamiento + análisis masivo
- TensorFlow: framework nativo con soporte completo
- Infraestructura de datos robusta

Debilidades:

- Menos maduro que AWS en algunos servicios
- Comunidad más pequeña
- Experiencia del equipo: Media

4.2.4 IBM Watson

Fortalezas:

- Especializado en enterprise AI
- AutoML capabilities

Debilidades:

- Precio muy elevado
- Comunidad limitada
- Menos servicios que competidores
- Experiencia del equipo: Nula
- Overkill para este proyecto

4.3 Justificación de Selección: AWS

RECOMENDACIÓN FINAL: AWS

AWS es la plataforma más apropiada por las siguientes razones:

1. **Escalabilidad:** SageMaker soporta millones de predicciones/día con auto-scaling
2. **Costo-beneficio:** Pricing por inferencia + Lambda serverless = economía
3. **Servicios integrados:** S3 + RDS + Lambda + CloudWatch = arquitectura completa
4. **Experiencia del equipo:** Equipo ha trabajado con AWS previamente
5. **Comunidad:** Recursos, documentation y soporte abundante
6. **Seguridad:** Compliance con GDPR, HIPAA, ISO 27001
7. **Roadmap:** Actualizaciones constantes de servicios ML

Score Final: 37/40 (92.5%)

5 Arquitectura de Producción Propuesta

5.1 Componentes Principales

Table 4: Componentes de la Arquitectura de Producción

Componente	Servicio AWS	Función
Ingesta de datos	API Gateway + Lambda	Recibir embeddings desde YOLO
Almacenamiento temporal	S3	Guardar embeddings y predicciones
Modelo ML	SageMaker Endpoint	Servir predicciones (inference)
Base de datos	RDS (PostgreSQL)	Persistencia de predicciones
Orquestación	Lambda + EventBridge	Trigger reentrenamiento automático
Monitoring	CloudWatch	Alertas y dashboards
Autoscaling	Auto Scaling Groups	Escalar Lambda/Endpoint según demanda

5.2 Flujo de Datos en Producción

```
Planta (YOLO)
|
v
[API Gateway]
|
v
[Lambda Function] (validar + pre-procesar)
|
+----> [SageMaker Endpoint]
|      |
|      v (predicción)
|      [Logistic Regression]
|      |
|      v
+----> [RDS] (almacenar predicción + confianza)
|
+----> [CloudWatch] (monitoreo)
|
+----> [SNS] (alertas si confianza < 0.75)
|
v
[Dashboard] (operadores planta)
```

5.3 Especificaciones Técnicas

SageMaker Endpoint:

- Instancia: ml.m5.xlarge (4 vCPU, 16 GB RAM)

- Modelo: V-JEPA 2 + Logistic Regression (serializado en joblib)
- Timeout: 30 segundos
- Concurrencia: 100 instancias (escala automática)
- Latencia esperada: 2-5ms por predicción

Lambda Function:

- Runtime: Python 3.11
- Memory: 512 MB
- Timeout: 60 segundos
- Triggers: API Gateway (síncrono), EventBridge (asíncrono)
- Concurrencia reservada: 1000

RDS PostgreSQL:

- Instancia: db.t3.medium (2 vCPU, 4 GB RAM)
- Storage: 100 GB gp3 (escalable)
- Backup: Diario, retención 30 días
- Multi-AZ: Sí (alta disponibilidad)
- Replicación de lectura: 2 réplicas para análisis

6 Procedimientos de Implementación

6.1 Cronograma de Despliegue (12 semanas)

Table 5: Timeline de Implementación en Producción

Semana	Hito	Deliverable
1-2	Setup AWS + IaC	VPC, IAM, S3, RDS configurados
3-4	SageMaker End-point	Modelo desplegado, test unitarios pass
5	Lambda Functions	API Gateway integrada, stress testing
6	Staging Deployment	Ambiente pre-prod con datos reales
7	Validación HITL	Operadores validan 500 predicciones
8	Monitoring Setup	CloudWatch, alertas, dashboards
9	Training Operadores	Workshops para planta
10	Canary Deployment	10% tráfico a nuevo modelo
11	Blue-Green Deployment	100% migración (rollback disponible)
12	Post-Deployment	Validación, ajustes, documentación final

6.2 Criterios de Éxito Fase Deployment

- SLO met: 99.9% uptime en staging 1 semana
- Latencia: p95 ¡ 10ms, p99 ¡ 50ms
- Accuracy en staging: $\geq 78\%$ (vs 78.54% en validación)
- Falsos positivos: $< 2\%$
- Operadores entrenados: 100%
- Documentación completa: SOP, runbooks, disaster recovery

7 Gestión de Riesgos

7.1 Riesgos Identificados y Mitigación

Table 6: Matriz de Riesgos y Mitigación

Riesgo	Probabilidad	Impacto	Mitigación
Drift del modelo en nuevos datos	Media	Alto	Monitoring mensual Fine-tuning trimestral
Latencia ≥ 10 ms en prod	Baja	Alto	Cacheing, SageMaker Async Replicación de lectura
Outage SageMaker	Muy baja	Crítico	Multi-AZ, fallback local
Data quality issue	Media	Medio	Validación de embeddings
Security breach	Baja	Crítico	TLS/SSL, VPC, IAM roles

8 Conclusión y Recomendación Final

8.1 Veredicto de Implementación

RECOMENDACIÓN: IMPLEMENTAR INMEDIATAMENTE

El modelo V-JEPA 2 cumple todos los criterios de éxito y está listo para despliegue en producción. Los resultados (78.54% accuracy, 0.9573 AUC) demuestran viabilidad técnica. AWS es la plataforma seleccionada como infraestructura cloud debido a su escalabilidad, costo-efectividad y servicios especializados.

8.2 Próximos Pasos Inmediatos

1. Aprobación del documento de implementación por stakeholders
2. Asignación de equipo (DevOps, Data Engineer, ML Ops)
3. Inicio de setup AWS (Semana 1)
4. Planificación de reentrenamiento continuo
5. Comunicación a operadores de planta

8.3 Sostenibilidad a Largo Plazo

El modelo es sostenible en producción con:

- Reentrenamiento mensual con datos nuevos
- Monitoreo continuo de drift y performance
- Rotación de on-call engineers para soporte 24/7
- Budget anual estimado: \$50-80K USD (AWS + equipo)
- Mejora esperada: De 78.54% a 85-88% en 6 meses