



Instituto Tecnológico y de Estudios Superiores de Monterrey

Maestría en Inteligencia Artificial Aplicada (MNA-V)

Proyecto Integrador
(Gpo 10)

Resumen Ejecutivo

Landy Haydee Schleich Osorio (Matrícula A01796374)

Carlos Pano Hernández (Matrícula A01066264)

Carlos Fernando Del Castillo Rey (Matrícula A01796595)

21 de Junio de 2026

1. Síntesis del Problema

Alignity IQ Edge, LLC opera en el sector de manufactura, donde la eficiencia en el piso de producción resulta un diferenciador competitivo clave. Actualmente, en los entornos industriales, la supervisión visual del piso de producción suele depender de la observación humana directa de monitores o recorridos presenciales para identificar incidentes, patrones operativos y cuellos de botella.

Este modelo de trabajo presenta tres principales problemas. El primero es la simultaneidad — un supervisor es incapaz de analizar múltiples zonas de trabajo al mismo tiempo manteniendo el mismo nivel de atención. El segundo es la reconstrucción — al término del turno no existe un registro estructurado de lo que ocurrió, cuándo ocurrió ni durante cuánto tiempo, lo que hace imposible el análisis post-turno sistemático. El tercero son los puntos ciegos — hay zonas del piso de producción que permanecen fuera del campo visual efectivo del supervisor durante periodos prolongados.

Lo anterior se traduce en tiempo muerto no detectado, cuellos de botella no atribuidos, y decisiones gerenciales basadas en observaciones incompletas. En manufactura, el tiempo no detectado es tiempo no recuperado.

Frente a esta situación, el Equipo #56 exploró la siguiente pregunta de investigación en colaboración con Alignity IQ Edge:

¿Puede un sistema de análisis de video multi-cámara basado en IA generar una bitácora visual automatizada que identifique patrones operativos, cuellos de botella y eventos críticos, reduciendo la necesidad de supervisión humana directa de monitores?

VisionOps es la respuesta a esa pregunta.

2. Hallazgos más importantes del análisis exploratorio de datos

El análisis exploratorio de datos (EDA) se realizó sobre **InHARD** (Industrial Human Action Recognition Dataset), como su nombre lo indica, éste es un dataset público especializado en reconocimiento de acciones humanas en entornos de manufactura. InHARD contiene 5,303 clips de video segmentados y etiquetados, distribuidos en 14 categorías de meta-acciones realizadas por 16 participantes distintos en condiciones controladas de laboratorio.

A través del EDA encontramos los siguientes puntos clave de partida para el proyecto:

- El dataset no presenta valores faltantes, lo que permitió trabajar directamente sobre los datos sin necesidad de imputación.
- Existe un desbalance de clases significativo: "Assemble system" concentra 1,378 clips (aproximadamente el 26% de todo el dataset) mientras que las clases minoritarias tienen menos de 50 muestras, lo que influye directamente en la estrategia de modelado.
- La cardinalidad de las acciones era originalmente de 103 etiquetas — las cuales se reducen a 12 clases limpias mediante la combinación de acciones redundantes, lo que mejora la capacidad de generalización del clasificador.

Es importante destacar que InHARD es un dataset generado a partir de un ambiente controlado — con condiciones ideales de iluminación, ángulos de cámara perfectos y etiquetado de las acciones. Los datos reales del piso de producción de Alignity IQ Edge u otras empresas pueden presentar una mayor variabilidad en aspectos de iluminación, oclusiones y estilos de movimiento distintos a los del dataset de referencia. Este es el principal factor a considerar en la fase de validación en sitio — y la razón por la que el componente de detección de inactividad se diseñó como un sistema zero-shot calibrable por zona, reduciendo la dependencia de etiquetas externas.

3. Modelos Generados

Siguiendo la metodología CRISP-ML y tomando como base los hallazgos de la fase EDA, el equipo siguió una progresión incremental en el desarrollo de modelos. El punto de partida fue un modelo baseline — un árbol de decisión entrenado sobre características cinemáticas extraídas de los bounding boxes del detector de personas — que confirmó que los datos visuales contenían señal suficiente para distinguir estados operacionales, pero evidenció su límite: las características geométricas simples no capturan la riqueza del movimiento humano en contextos industriales. El desbalance de clases identificado en el EDA nos proporcionó el punto de partida para evolucionar hacia una arquitectura más robusta, reutilizando modelos apropiados para el problema a resolver.

El siguiente paso fue seleccionar un backbone de visión computacional capaz de entender el movimiento a lo largo del tiempo. Tras comparar múltiples arquitecturas — incluyendo DINOv2 y variantes del modelo MC-JEPA — V-JEPA2 de Meta AI demostró la mejor separabilidad de representaciones en tareas de clustering sobre InHARD, medida por los índices ARI y NMI. V-JEPA2 fue preentrenado con millones de videos y se mantiene completamente congelado en VisionOps — sus parámetros nunca se modifican, lo que garantiza reproducibilidad y elimina el riesgo de sobreajuste.

A partir de esta arquitectura, el equipo desarrolló dos componentes complementarios que en conjunto responden la pregunta de investigación del proyecto.

1. **Clasificador Supervisado de 12 acciones.** Tras experimentar con clasificadores lineales (56% de accuracy), un MLP simple (81%) y múltiples estrategias de fusión de vistas, el resultado final fue un ensemble de 7 MLPs con combinación por Power Mean $q=0.5$, entrenado sobre embeddings fpc64 multi-vista de InHARD. Esta arquitectura de ensemble reduce la varianza individual de cada modelo y es más robusta al desbalance de clases que el promedio aritmético simple. El resultado fue 87.8% de accuracy y F1 macro de 0.861 sobre 12 clases de acciones manufactureras.
2. **Detector de inactividad zero-shot.** Este componente calcula la similitud entre el embedding del video de una zona de trabajo y un prototipo de "No action" construido a partir de clips de InHARD, sin necesidad de entrenar ningún clasificador adicional. Un mecanismo de suavizado temporal con mayoría de votos confirma la inactividad solo cuando se sostiene en múltiples clips consecutivos, eliminando falsas alarmas. El resultado fue 88% de accuracy y AUC-ROC de 0.904 sobre datos de validación.

Ambos componentes operan sobre el mismo backbone V-JEPA2 congelado, comparten la misma infraestructura de extracción de embeddings, y se complementan funcionalmente: el detector de inactividad identifica cuándo no hay actividad productiva, y el clasificador de acciones identifica qué actividad específica está ocurriendo cuando la zona está activa.

4. Recomendaciones clave para implementar la solución

Con la arquitectura definida previamente, VisionOps está listo para una fase de piloto en la planta de Alignity IQ Edge. Para dicha implementación, el equipo identifica tres etapas para el despliegue en producción:

- **Etapas 1 – Inmediata:** habilitar la inferencia en GPU — la latencia actual en CPU es de aproximadamente 2.8 segundos por clip de video, lo que no es compatible con monitoreo en tiempo real; con GPU esa latencia baja a menos de 200 milisegundos. Adicionalmente, es necesario calibrar el umbral de detección con una muestra de video real de la planta — el umbral actual fue calibrado sobre InHARD y requiere ajuste por zona y condiciones de iluminación propias del sitio.
- **Etapas 2 – A corto plazo (1 a 3 meses):** posterior a contar con acceso a las cámaras del piso de producción, se requiere calibrar el umbral de detección de inactividad por zona y condiciones de iluminación reales del sitio a profundidad. Por otro lado, es necesario grabar clips etiquetados para re-validar el clasificador de 12 acciones fuera del entorno controlado de InHARD. Adicionalmente, completar el experimento de T=16 frames podría aportar entre 2 y 4 puntos adicionales de accuracy sin cambios arquitectónicos.
- **Etapas 3 – A largo plazo (3+ meses):** para infraestructura en la nube, se recomienda AWS como plataforma de despliegue por su madurez en servicios de ML, escalabilidad multi-cámara y experiencia previa del equipo. La arquitectura propuesta conecta los tres servicios de VisionOps — backend, alertas y dashboard — con SageMaker para inferencia, RDS para persistencia de eventos y CloudWatch para monitoreo continuo.

5. Análisis de costo – beneficio

Los siguientes supuestos se establecen para contextualizar las cifras presentadas a las partes interesadas. Todos los valores son estimaciones basadas en referentes del mercado de manufactura y servicios cloud en 2026.

Supuestos Base:

- Planta con 2 turnos de trabajo, 250 días operativos al año
- Fase piloto: 15 a 20 cámaras IP conectadas via RTSP/ONVIF
- Costo promedio de un supervisor de planta: \$75,000 USD anuales
- Valor de producción por turno de 8 horas: \$8,000 USD
- Tiempo muerto promedio no detectado actualmente: 12% del turno

Costos por fase CRISP-ML:

Fase CRISP-ML	Concepto	Costo Estimado
Entendimiento del negocio y datos	Investigación, EDA, dataset InHARD (público)	\$0
Preparación de datos	Limpieza, preprocesamiento	\$0
Modelado	Cómputo en GPU (Google Colab Pro, entrenamiento 7 MLPs)	~\$150 USD
Evaluación	Validación experimental	\$0
Total por desarrollo / implementación		~\$150 USD

Las fases de desarrollo, modelado y evaluación fueron ejecutadas por el Equipo #56 como proyecto integrador de la Maestría en Inteligencia Artificial Aplicada del Instituto Tecnológico de Monterrey. El costo de desarrollo para Alignity IQ Edge en estas fases es de \$0 — lo que representa una inversión en I+D subsidiada por la colaboración academia-industria. Los costos listados corresponden exclusivamente a infraestructura técnica y despliegue.

Costos de Operación Mensual (fase piloto):

Concepto	Costo Estimado
GPU server para inferencia en tiempo real	~\$1,200 USD
Infraestructura AWS (SageMaker + RDS + S3 + CloudWatch)	~\$1,800 USD
Total operación mensual	~\$3,000 USD
Total operación anual	~\$36,000 USD

Costos de Mantenimiento:

El mantenimiento del modelo requiere una sesión trimestral de re-calibración con datos nuevos de la planta, estimada en aproximadamente ~20 horas de trabajo técnico por ciclo.

Beneficios potenciales

El beneficio central de VisionOps es la conversión de tiempo muerto no detectado en tiempo productivo recuperable. Con un 12% de tiempo muerto promedio por turno y una reducción conservadora del 25% gracias a las alertas en tiempo real, el sistema liberaría aproximadamente el 3% de capacidad productiva por turno — equivalente a \$240 USD de valor de producción por turno, o \$120,000 USD anuales en una planta de 2 turnos operando 250 días.

A eso se suman tres beneficios estratégicos de alto valor para Alignity IQ Edge: la bitácora visual post-turno como activo de conocimiento operacional, la trazabilidad de acciones por zona para cumplimiento de SOPs, y la capacidad de escalar el monitoreo a múltiples plantas sin incrementar proporcionalmente el número de supervisores.

Basado en los supuestos establecidos, el punto de equilibrio entre costo de operación (\$36,000 USD anuales) y beneficio estimado (\$120,000 USD anuales) indica un retorno de inversión de aproximadamente 3.3x en el primer año completo de operación.

6. Riesgos y desafíos

Riesgos de datos

El riesgo más latente en la solución, en esta etapa, es la brecha entre el entorno de entrenamiento y el entorno de producción. Los modelos fueron entrenados sobre InHARD, un dataset que ya hemos mencionado tiene condiciones muy controladas de iluminación, ángulos de cámara fijos y etiquetado preciso. Los datos reales de la planta de Alignity IQ Edge o cualquier otra planta presentarán variaciones, así como acciones no contempladas en las 12 clases de InHARD.

Un segundo riesgo que identificamos en cuestión de datos es el desbalance de clases heredado de InHARD, donde acciones frecuentes como "Assemble system" concentran el 26% de los ejemplos mientras que acciones poco frecuentes tienen menos de 50 muestras. Las clases minoritarias presentan accuracy variable entre 50% y 70%, lo que puede generar predicciones menos confiables para acciones específicas en producción.

Ambos riesgos los estimamos mitigar con la fase de calibración en sitio y la re-validación del clasificador con clips etiquetados de la planta real.

Riesgos de ataques

Los streams de video RTSP/ONVIF transmiten datos sensibles del piso de producción. Sin cifrado adecuado, estos flujos son vulnerables a interceptación. La arquitectura propuesta en AWS mitiga esto con TLS/SSL y VPC aisladas, pero la conexión entre las cámaras físicas de la planta y el backend requiere configuración de red segura en sitio.

Riesgos de prueba y confianza

El principal riesgo en esta categoría es el sesgo de evaluación acumulado en los experimentos del clasificador de 12 acciones. Múltiples pruebas sobre el mismo test set de InHARD pueden haber inflado la confianza en el 87.8% de accuracy reportado. Antes del despliegue definitivo se requiere validar el modelo sobre un holdout nuevo que no haya sido visto durante ninguna iteración experimental.

El modelo puede además presentar drift en producción: conforme cambian las condiciones de la planta (nuevos operarios, cambios de turno, reconfiguración de estaciones de trabajo), el rendimiento puede degradarse gradualmente sin que sea evidente de inmediato. La mitigación es el monitoreo continuo con CloudWatch y sesiones trimestrales de re-calibración, como ya mencionamos.

Riesgos de cumplimiento

La solución analiza video de operarios en su ambiente de trabajo. Esto implica consideraciones de privacidad y derechos laborales que varían según la jurisdicción. En Texas, donde opera Alignity IQ Edge, no existe una ley estatal específica de privacidad biométrica equivalente a BIPA en Illinois, pero el monitoreo de trabajadores requiere notificación y, según la política interna de la empresa, posible consentimiento. Como señala Miller (2022), los operarios del piso de producción son stakeholders pasivos del proyecto — afectados por el sistema pero sin poder sobre él — y deben ser considerados en el diseño de la solución.

Adicionalmente, el paper académico del proyecto debe publicarse exclusivamente con datos de InHARD (dataset público) sin incluir imágenes, embeddings ni metadatos del sitio real de Alignity IQ Edge, conforme al NDA firmado. Esto requiere la aprobación escrita del sponsor con al menos 45 días de anticipación antes del envío.

7. Bibliografía

Visengeriyeva, L., Kammer, A., Bär, I., Kniesz, A., y Plöd, M. (2023). *CRISP-ML(Q). The ML Lifecycle Process*. MLOps. INNOQ.

Baccarin, F. (2020, diciembre 28). Machine learning that pays the bills: choosing models in business contexts. Medium.

Babic, B., Cohen, I.G., Evgeniou, T., y Gerke, S. (2021). When Machine Learning Goes Off the Rails. Harvard Business Review.

Miller, G. J. (2022). Stakeholder roles in artificial intelligence projects. *Project Leadership and Society*, 3, 100068. <https://doi.org/10.1016/j.plas.2022.100068>

Korolov, M. (2022, septiembre 7). Measuring the business impact of AI. CIO. <https://www.cio.com/article/405620/measuring-the-business-impact-of-ai.html>

Nguyen, N. T., et al. (2021). InHARD - Industrial Human Action Recognition Dataset in the Context of Industrial Assembly Line. WACV Workshop on Human Activity Recognition in Real-Life and Automated Surveillance.

Bardes, A., Garrido, Q., Ponce, J., Chen, X., LeCun, Y., & Assran, M. (2024). Revisiting Feature Prediction for Learning Visual Representations from Video. arXiv:2404.08471.

Glassdoor. (2026). Production Supervisor salaries at Ford Motor Company. <https://www.glassdoor.com/Salary/Ford-Motor-Company-Production-Supervisor-Salaries>